

A Transformada Quântica de Fourier no teto de 28 qubits

Metodologia, verificação numérica e comparativo com o `cuStateVec`

RGPU — simulação quântica em WGS� portátil (`rqubit`)

13 de setembro de 2026

Resumo

Este relatório documenta a execução da Transformada Quântica de Fourier (QFT) completa — o circuito canônico de benchmark, com $O(n^2)$ portas — no maior estado que o binding do WebGPU permite: 27 qubits em precisão simples e **28 qubits em meia precisão**, 420 portas, cada uma uma passada completa por 1 GiB de estado. A carga foi medida no `rqubit` (kernels WGS� sobre Vulkan, sem CUDA) e no `cuStateVec`, a biblioteca de vetor de estado da própria NVIDIA, na mesma máquina. Resultados principais: empate técnico com o `cuStateVec` em precisão simples (ambos a $\sim 224\text{--}228$ GB/s), ganho de $2,43\times$ em tempo e $2,44\times$ em energia com a fusão de portas até 6 qubits, e $1,96\times$ em tempo no teto de 28 qubits, onde a meia precisão faz o papel que o `cuStateVec` não oferece. Dois resultados negativos foram medidos e registrados: a fusão até 6 qubits *perde* em 22 qubits, e a fusão de 2 qubits em `f16` economiza tempo e *gasta* energia.

1 Introdução e objetivo

Portas isoladas medem o kernel; um algoritmo mede a pilha. O objetivo deste experimento é submeter o `rqubit` — simulador de vetor de estado quântico em Rust puro, sobre `wgpu`/WGS� — a uma carga com a estrutura de um algoritmo de verdade e compará-lo, na mesma máquina e na mesma carga, ao `cuStateVec` da NVIDIA. A QFT foi escolhida por três razões:

- é o circuito de benchmark canônico, usado em demonstrações do Qiskit e do cuQuantum, o que torna o comparativo reconhecível;
- tem fator de ramificação alto: fases controladas entre *todos* os pares de qubits, o que estressa tanto o kernel de 2 qubits quanto a fusão;
- escala com $O(n^2)$ portas, o que permite chegar ao teto de qubits da máquina sem explosão de tempo.

O experimento também serve de primeiro uso real do produto interno em GPU ($\langle a|b \rangle$), implementado em dois estágios sobre o mesmo vetor de estado: é ele que prova, depois da QFT completa, que a norma do estado sobreviveu a 420 portas.

2 Metodologia

2.1 O circuito

A QFT segue a forma padrão com o qubit q de peso 2^q :

1. para cada $j \in \{0, \dots, n-1\}$: Hadamard em q_j , seguida de portas controladas-fase $\text{CP}(2\pi/2^{k-j})$ entre todo par (q_k, q_j) com $k > j$;
2. reversão final da ordem dos qubits por SWAPs.

O total é $n + n(n-1)/2 + n/2$ portas — 264 em 22 qubits, 364 em 26, 391 em 27 e **420 em 28**. A inversa exata, usada na verificação de ida-e-volta, inverte a ordem das portas e troca o sinal dos ângulos.

A porta controlada-fase $CP(\theta) = \text{diag}(1, 1, 1, e^{i\theta})$ não existe pronta na API; foi construída diretamente sobre o campo público de matriz de `Porta2`, com a fase no elemento `[3][3]` — a convenção de índices (`[11]` por último) foi verificada no kernel e em `aplicar_cpu`.

2.2 A pilha e as precisões

O `rqubit` guarda o vetor de estado residente na GPU como um único buffer. O teto de qubits é imposto pelo limite de binding do WebGPU (2 GB menos 4 bytes):

- **f32 (complex64):** 8 B por amplitude $\Rightarrow$ **27 qubits** (1 GiB);
- **f16 empacotado:** 4 B por amplitude $\Rightarrow$ **28 qubits** (1 GiB) — 29 qubits exigiriam exatamente 2 GiB, acima do limite.

Cada porta é uma passada completa pelo vetor de estado; numa carga limitada por banda de memória, o tempo por porta é governado pelos bytes movidos (leitura + escrita). A fusão de portas reduz o número de passadas: a fusão de 2 qubits absorve portas de 1 qubit pendentes na porta de 2 seguinte; a fusão até 6 qubits usa os kernels especializados (amplitudes em registradores, índices literais), que só existem em `f32`.

2.3 Protocolo de medição

- **Tempo:** uma execução de aquecimento, depois três execuções cronometradas; o valor reportado é a média por circuito. Cada execução aplica a QFT inteira sobre o estado corrente — o custo das portas não depende do estado.
- **Energia do `rqubit`:** janela calibrada de pelo menos ~ 4 s (repetições ajustadas por circuito, mínimo de 3), medida pelo `rgpu-power` via `nvidia-smi`, com ociosidade calibrada antes de cada rodada.
- **Energia do `cuStateVec`:** medida por fora do processo (`medir_externo`), pela diferença entre uma execução só de partida (`reps=0`) e a execução com R repetições, dividida pelo número de circuitos de fato executados (aquecimento incluso). Os dois instrumentos não são idênticos; os números de energia são comparáveis com ressalva.
- **Comparativo:** `cuStateVec` via `cuquantum-python` (precisão simples, `complex64`), matrizes pré-carregadas no dispositivo, `venv` dedicado fora do repositório. O Aer (CPU) não entrou nesta rodada; a GPU dele não foi instalada (incompatível com o Qiskit 2.5) e a comparação GPU $\times$ CPU já está coberta no README para portas isoladas.

3 Testes de verificação

A medição só vale se a física estiver de pé. Três verificações acompanham a execução, todas com o produto interno em GPU como instrumento:

O desvio do `f16` ($\approx -2,9 \cdot 10^{-3}$ na norma) é o erro de arredondamento acumulado de centenas de portas cujos ângulos não são representáveis em meia precisão — mesma ordem de grandeza medida em testes unitários de rotações. Um efeito estrutural vem de graça: ângulos CP abaixo da resolução de `f16` ($\sim 5 \cdot 10^{-4}$) agem como identidade, de modo que a QFT em `f16` é *aproximada por construção* — a QFT aproximada da literatura, sem custo extra de implementação.

Teste	O que prova	Medido	Tolerância
8 qubits: QFT GPU contra CPU	correção do circuito	erro máx. $1,12 \cdot 10^{-8}$	10^{-4}
8 qubits: $ \text{amplitude} $	estrutura da QFT de $ x_0\rangle$	0,0625 exato	$1/\sqrt{N}$
27 qubits f32 : $\langle\psi \psi\rangle$ após QFT	normalização	0,999997	10^{-4}
27 qubits f32 : $\langle x_0 \text{QFT}^{-1}\text{QFT} x_0\rangle$	cadeia de 782 portas	0,999998	10^{-4}
28 qubits f16 : $\langle\psi \psi\rangle$ após QFT	normalização em f16	0,997077	10^{-2}
28 qubits f16 : ida-e-volta (785 portas fundidas)	física em f16	0,998535	10^{-2}

Tabela 1: Verificações numéricas. O estado inicial $|x_0\rangle$ é preparado com portas X (padrão de bits alternados; em 8 qubits, $x_0 = 0b10110001$).

Qubits	Prec.	Portas	Fundidas	ms/circuito	ms/porta	Banda (GB/s)
22	f32	264	264 (direto)	67,6	0,256	—
22	f32	264	242 (fusão-2)	55,8	0,230	—
22	f32	264	56 (fusão-6)	90,7	1,620	—
24	f32	312	312 (direto)	392,2	1,257	—
24	f32	312	60 (fusão-6)	199,8	3,329	—
26	f32	364	364 (direto)	1.758,7	4,832	212
26	f32	364	68 (fusão-6)	756,2	11,121	494
26	f16	364	364 (direto)	925,2	2,542	403
26	f16	364	338 (fusão-2)	822,4	2,433	455
27	f32	391	391 (direto)	3.745,2	9,579	224
27	f32	391	82 (fusão-6)	1.539,7	18,777	524
28	f16	420	420 (direto)	4.031,6	9,599	224
28	f16	420	392 (fusão-2)	3.763,9	9,602	240

Tabela 2: QFT completa no `rqubit`. A “banda” é o tráfego efetivo ($2\times$ o estado por porta, $2\times$ as portas fundidas por circuito), não um teto de hardware. Em **f16**, 28 qubits não têm contraparte **f32** (o binding não permite), e a fusão-6 não existe (os kernels de N qubits são só em **f32**).

4 Resultados de tempo

O caso direto é governado por banda: em 27 e 28 qubits o tráfego efetivo fica em ~ 224 GB/s de ~ 256 disponíveis. O previsto pela banda ($420 \text{ portas} \times 2 \text{ GiB} \div 200 \text{ GB/s} \approx 4,2 \text{ s}$) deu 4,03 s medidos — dentro de 5%.

5 Resultados de energia

Dois destaques. A meia precisão faz **3,3× menos energia** que a simples no mesmo circuito (36,6 contra 120,9 J em 26 qubits) — mais que os $2\times$ dos bytes, porque a potência média também cai. E a fusão de 2 qubits em **f16** *custa* energia: 822 ms contra 925 (ganho de 11%), mas 48,9 J contra 36,6 J (+34%). A Hadamard absorvida no CP faz aritmética extra por byte; num regime limitado por banda isso não compra tempo — cobra watt. É a quarta vez neste repositório em que a medição de energia contradiz a de tempo.

6 Comparativo com o `cuStateVec`

Leitura 1 — empate técnico em precisão simples. Sem fusão, o `rqubit` mede 3.745 ms contra 3.685 do `cuStateVec` em 27 qubits (1,6%), e 1.759 contra 1.716 em 26. Os dois saturam a banda de DRAM (~ 224 – 228 GB/s calculados); quando o gargalo é mover bytes, um kernel

Qubits	Prec.	rqubit direto	rqubit fusão-6	cuStateVec (por fora)
26	f32	120,9 J	47,8 J	~65,5 J
26	f16	36,6 J	—	~65,5 J
27	f32	249,0 J	102,0 J	—
28	f16	246,4 J	—	~288,3 J

Tabela 3: Energia por circuito. A coluna do `cuStateVec` vem de medição externa (diferença entre execução de partida e execução com carga, dividida pelos circuitos executados); a do `rqubit`, do medidor integrado. Métodos distintos: comparar com ressalva.

Qubits	rqubit direto	rqubit fusão-2	rqubit fusão-6	cuStateVec	Melhor
22	67,6	55,8	90,7	37,7	cuStateVec 1,8×
24	392,2	362,1	199,8	367,2	rqubit 1,84×
26	1.758,7	1.636,1	756,2	1.716,2	rqubit 2,27×
26 (f16)	925,2	822,4	—	1.716,2	rqubit 2,09×
27	3.745,2	3.480,5	1.539,7	3.685,0	rqubit 2,39×
28 (f16)	4.031,6	3.763,9	—	7.916,4	rqubit 1,96×

Tabela 4: ms por circuito (QFT completa). `cuStateVec` em precisão simples; não oferece meia precisão para vetor de estado.

WGSL portátil e a biblioteca proprietária da NVIDIA chegam ao mesmo lugar. É o mesmo resultado do README para portas isoladas, agora num algoritmo completo.

Leitura 2 — a fusão é o diferencial. Os CPs consecutivos sobre o mesmo qubit alvo fundem-se em unitárias de até 6 qubits: 391 portas viram 82, e o circuito cai 2,43× em tempo e 2,44× em energia. A comparação é justa na direção do que cada API entrega: o `cuStateVec` é de baixo nível e não funde portas; a fusão do `rqubit` é parte da pilha medida. A NVIDIA tem camadas superiores (`cutensornet`) que fariam otimização equivalente — a ressalva já registrada no README vale aqui.

Leitura 3 — o regime pequeno pertence ao `cuStateVec`. Em 22 qubits o estado (32 MiB) cabe na L2 da placa: as passadas ficam baratas, o custo fixo por dispatch domina, e o `cuStateVec` — com despacho mais leve (0,143 ms/porta contra 0,256) — vence 1,8×. Nesse regime, cortar passadas não rende: a fusão até 6 qubits é 34% *mais lenta* que o caminho direto. O cruzamento fica entre 22 e 24 qubits e não foi varrido.

Leitura 4 — meia precisão compra um qubit inteiro. No teto, o `rqubit` em f16 faz a QFT de 28 qubits em 4,03 s contra 7,92 s do `cuStateVec` em f32 (1,96×) e ~288 J contra 246 J. A conta é de banda: ambos movem bytes a ~224–228 GB/s; o f16 move metade dos bytes por porta e, portanto, cabe um estado com o dobro de amplitudes no mesmo tempo.

7 Ameaças à validade

- **Deriva térmica:** GPU de notebook muda de clock sozinha; efeitos abaixo de ~20% não são resolvíveis por cronometragem de parede nesta máquina (registro em `RESULTADOS-NEGATIVOS.md`). As linhas do comparativo foram medidas em sessões separadas; o empate de 27 qubits (1,6%) está dentro dessa margem e deve ser lido como empate, não como vitória do `cuStateVec`.
- **Métodos de energia distintos:** medidor integrado (`rqubit`) contra medição externa do processo (`cuStateVec`), com janelas e composições de ociosidade diferentes. As diferenças de energia abaixo de ~30% não são conclusivas; as de 2× ou mais, sim.

- **Repetição sobre estado corrente:** as repetições aplicam a QFT sobre o estado já transformado. O custo das portas não depende do estado, mas o padrão de bits pode afetar consumo de forma residual.
- **Água no aquecimento do cuStateVec:** a partida do Python e a inicialização do CUDA foram isoladas pela diferença entre `reps=0` e `reps> 0`; o resíduo de partida é da ordem de 47 J.

8 Conclusões

No algoritmo canônico de benchmark, no maior estado que a máquina comporta:

1. o kernel WGS� portátil **empata com o cuStateVec** quando ambos limitados pela mesma banda de DRAM;
2. a **fusão de portas até 6 qubits** é o diferencial de arquitetura ($2,43\times$ tempo, $2,44\times$ energia acima de 24 qubits) — e perde abaixo dele, onde a L2 muda o regime;
3. a **meia precisão** entrega um qubit a mais ($1,96\times$ contra o cuStateVec) e $3,3\times$ menos energia, ao custo de uma QFT aproximada cujo erro medido fica em $\sim 10^{-3}$;
4. a **energia voltou a contradizer o tempo:** a fusão de 2 qubits em f16 economiza passadas e gasta watts.

A Reprodutibilidade

```
# rqubit: QFT completa (verificações + tabela; 'tabela' refaz só as medições)
cargo run -p rqubit --release --example bench_qft
cargo run -p rqubit --release --example bench_qft -- tabela 27:f32 28:f16
```

```
# cuStateVec (venv dedicado, fora do repositório)
export LD_LIBRARY_PATH=$(find ~/.cache/rgpu-benchmarks/quantum \
    -name lib -maxdepth 2 -type d | tr '\n' ':')
python benchmarks/quantum/bench_custatevec_qft.py 28 3 single
```

```
# energia do processo externo
cargo run -p rqubit --release --example medir_externo -- \
    ~/.cache/rgpu-benchmarks/quantum/bin/python \
    benchmarks/quantum/bench_custatevec_qft.py 26 6 single
```

Máquina: RTX 4070 Laptop (8 GB), Intel Meteor Lake, wgpu/Vulkan, driver NVIDIA 595.91.07. Versões: burn 0.21, TensorFlow 2.21.0, PyTorch 2.14.0, Qiskit 2.5, cuquantum-python-cu12.